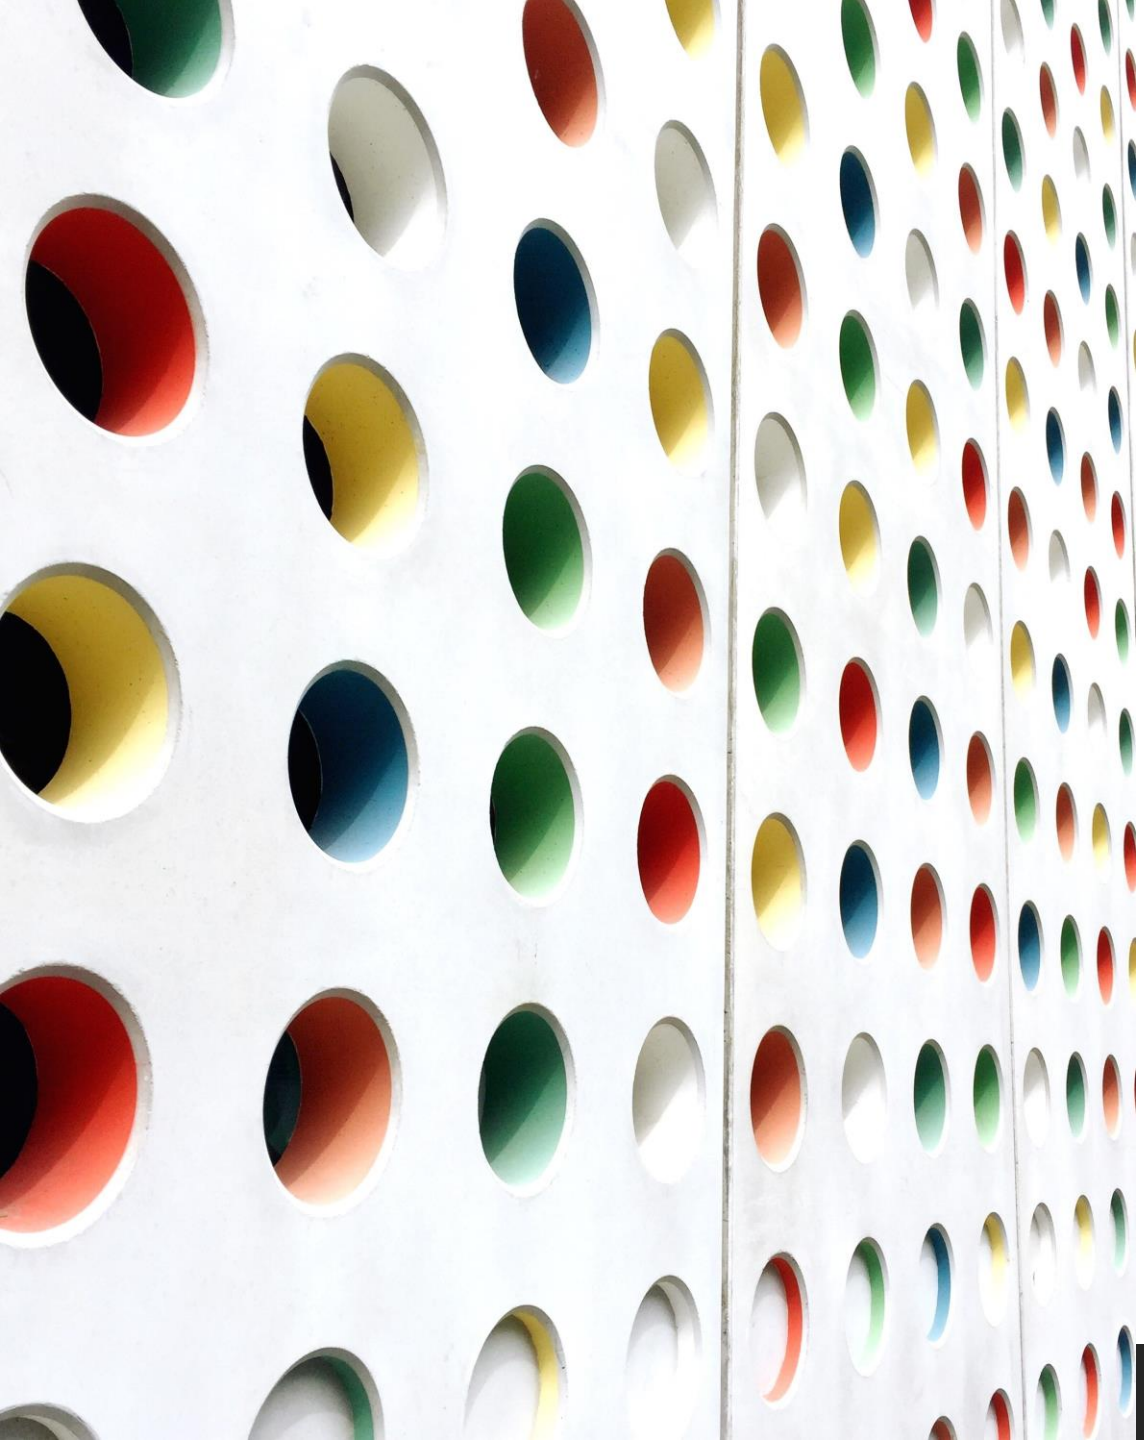

Déployez un modèle dans le cloud

PARCOURS DATA SCIENTIST
FINANCÉ PAR PÔLE EMPLOI

MENTOR : GAËTAN GOLLIOT

ÉVALUATEUR : DAN SLAMA

ÉTUDIANTE : VERONIKA BEREZHNAIA

Sommaire

RAPPEL DE LA PROBLÉMATIQUE ET PRÉSENTATION DU JEU DE DONNÉES (5 MINUTES)

CRÉATION D'UN ENVIRONNEMENT BIG DATA DANS LE CLOUD ET RÉALISATION DE LA CHAÎNE DE TRAITEMENT DES IMAGES (18 MINUTES)

CONCLUSION ET RECOMMANDATIONS (2 MINUTES)

Problématique

Mon entreprise souhaite créer une application mobile qui permettrait aux utilisateurs de prendre en photo un fruit et d'obtenir des informations sur ce fruit.

Le développement de l'application mobile permettra de construire une première version de l'architecture Big Data nécessaire.

Ma mission

Développer dans un **environnement Big Data** une première chaîne de traitement des données qui comprendra le **préprocessing** et une étape de **réduction de dimension**.

Le volume de données va augmenter très rapidement après la livraison de ce projet. Il faut donc **des scripts en Pyspark sur le cloud AWS** pour profiter d'une architecture Big Data (EC2, S3, IAM), basée sur un serveur EC2 Linux.

Il faudra probablement **payer** pour avoir plus de RAM que dans le modèle gratuit, qui en offre juste 1 Go. Ou il faut **trouver un contournement**.

Les objectifs / les pourquoi

Pourquoi utiliser les scriptes Spark au lieu de scriptes standards Python, comme la bibliothèque SKLearn qui étaient utilisés dans tous les projets précédents ?

Pour pouvoir traiter un très grand nombre de données. Plusieurs gigabytes voire des dizaines de gigabytes. Spark permet utiliser plusieurs ordinateurs en parallèle, chacun d'eux possédant plusieurs processeurs.

Pourquoi passer à un cloud AWS ?

Le cloud - pour pouvoir louer ces pouvoirs des calculs et de stockage, avec des dizaines des machines, sans avoir besoin de les acheter.

Pourquoi choisir l'AWS – parce qu'il est proposé dans le cours, et qu'il existe le plus de matériel expliquant et montrant comment l'utiliser.

Jeu de données (1,28 Gb)

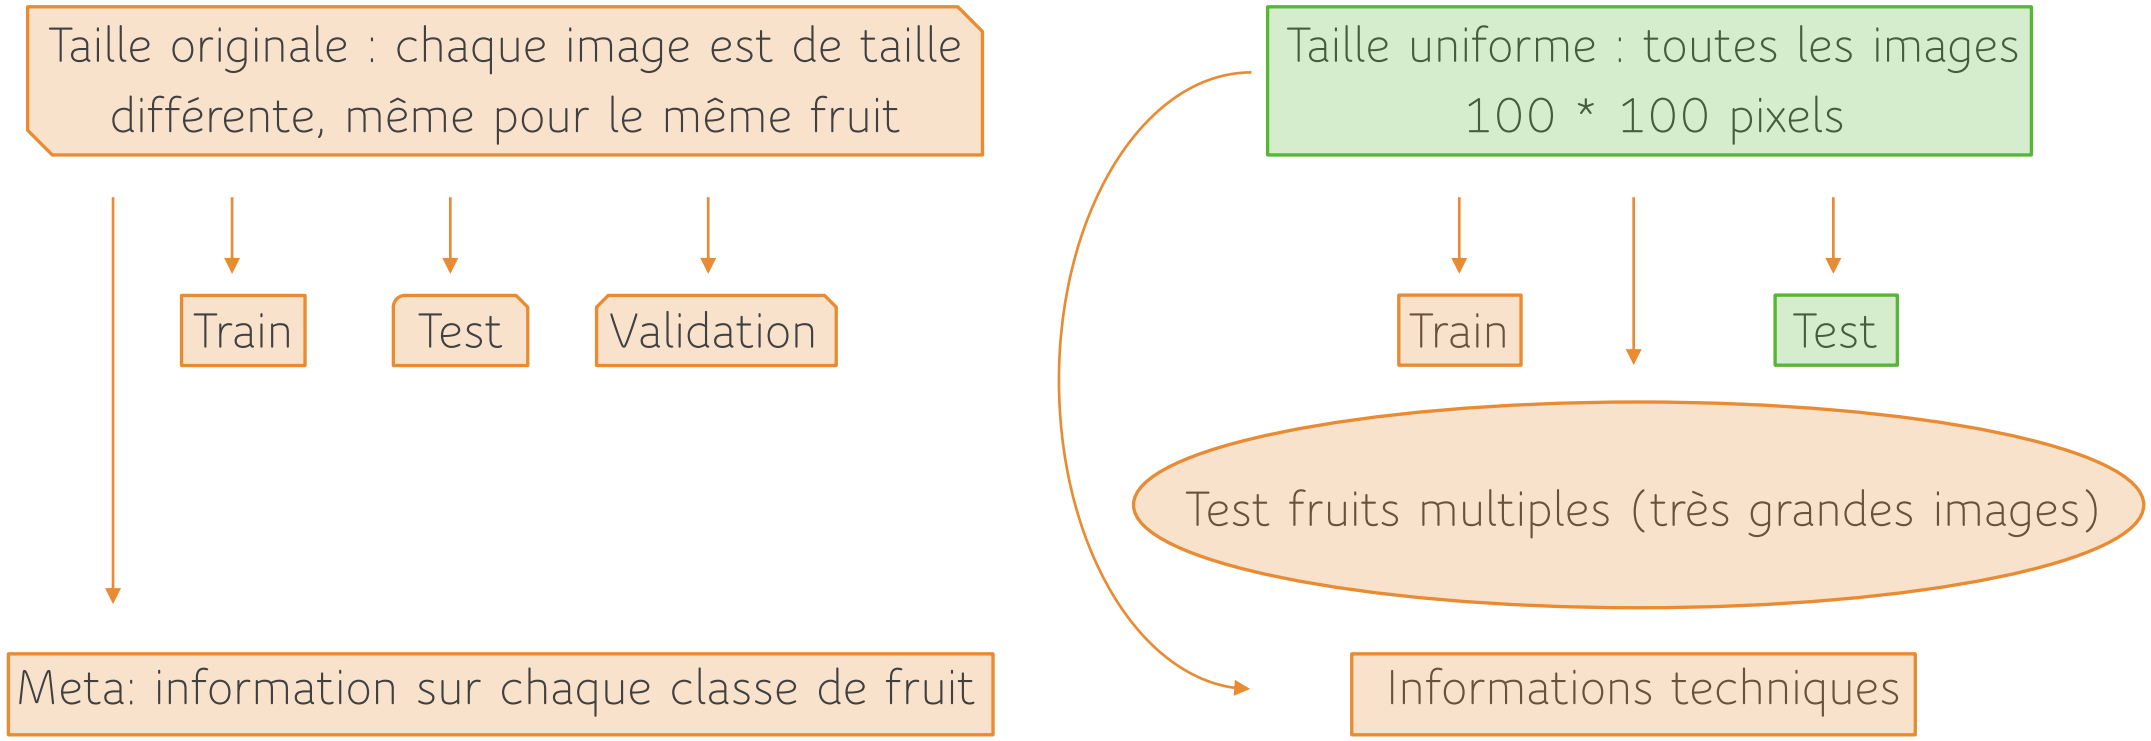

Le plan de travail

Installer et configurer la machine virtuelle Linux sur ma machine Windows

Installer et configurer Anaconda, Spark, Tensorflow (environnements isolés ne sont pas nécessaires)

Tester le code: jusqu'à l'étape d'écrire le fichier .csv dans un dossier

S'inscrire à AWS avec sa carte bancaire

Apprendre offre gratuite et ses limites

Ouvrir un serveur EC2 avec son EBS, ouvrir un Bucket S3

Anaconda, Pyspark, Tensorflow (pas de conflits entre Tensorflow et autres bibliothèques?)

Assurer l'interaction de EC2 et S3

Tester le code. Pour le faire sans dépasser la RAM:

- Configurer son serveur: Swap (allouer de l'espace disque à RAM)
- Augmenter la taille de son EBS et augmenter le Swap

Offre gratuite

Dans le cadre de l'offre gratuite, la taille de toutes les services reste identique

Dans les services payantes, les prix varient en fonction de la région

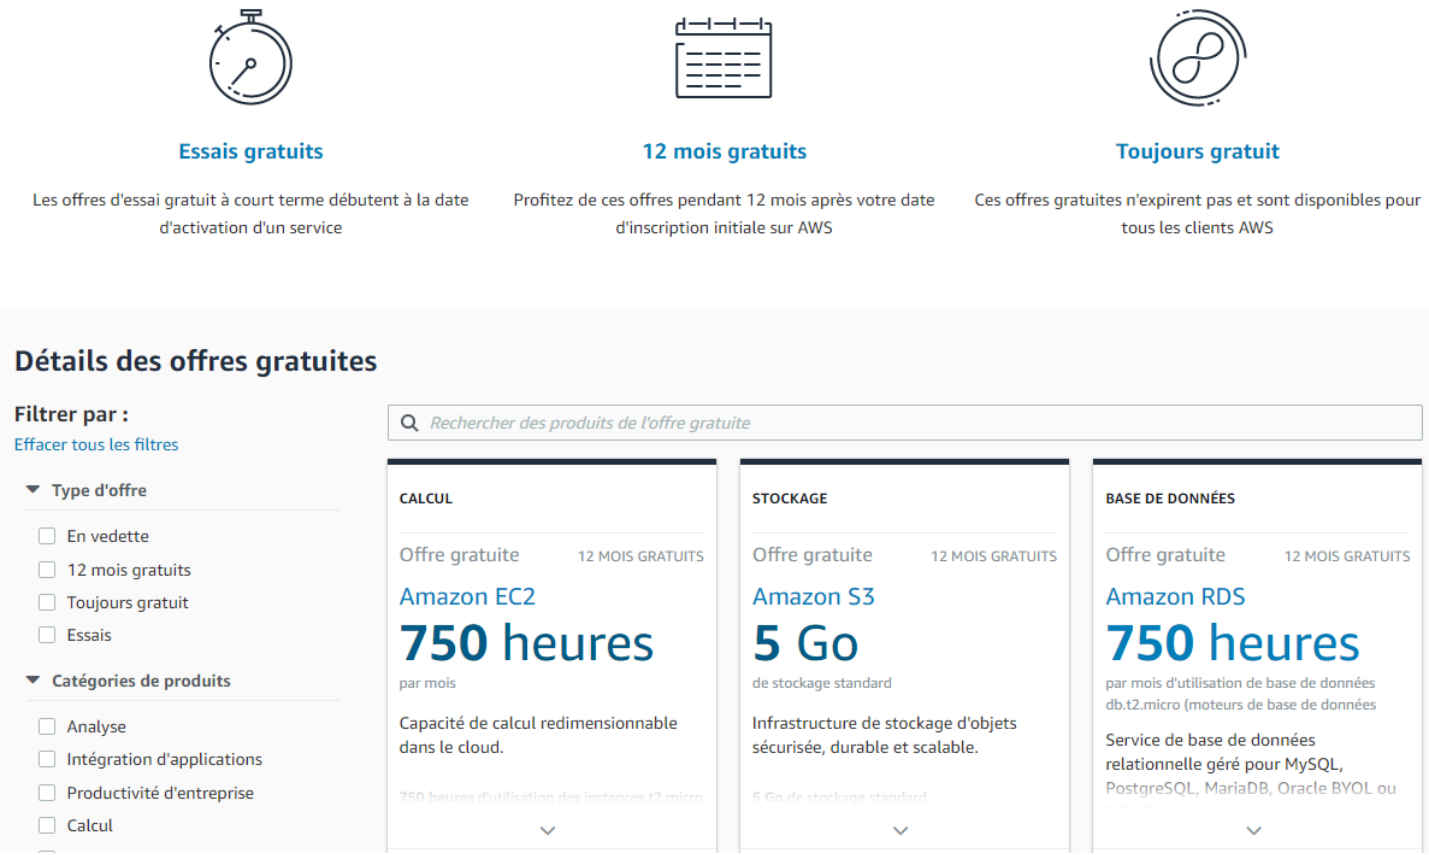

Utilisation d’offre gratuite

Service	AWS Free Tier usage limit	Current usage	Forecasted usage	MTD actual usage %	MTD forecasted usage %
Amazon Simple Storage Service	2,000 Put, Copy, Post or List Requests of Amazon S3	2,000 Requests	4,769 Requests	100.00%	238.46%
Amazon Elastic Compute Cloud	750 hours per month of Amazon EC2 Linux, RHEL, or SLES t2.micro or t3.micro instance dependent on region	303 Hrs	723 Hrs	40.40%	96.34%
Amazon Simple Storage Service	20,000 Get Requests of Amazon S3	4,457 Requests	10,628 Requests	22.29%	53.14%
Amazon Elastic Compute Cloud	30 GB of Amazon Elastic Block Storage in any combination of General Purpose (SSD) or Magnetic	6 GB-Mo	14 GB-Mo	19.83%	47.28%
AWS Key Management Service	20,000 free requests per month for AWS Key Management Service	20 Requests	48 Requests	0.10%	0.24%
Amazon Simple Storage Service	5 GB of Amazon S3 standard storage	0 GB-Mo	0 GB-Mo	0.01%	0.01%
AmazonCloudWatch	1,000,000 API requests for Amazon Cloudwatch	1 Requests	2 Requests	0.00%	0.00%
Amazon Simple Notification Service	1,000,000 Requests for Amazon Simple Notification Service (EUC1)	1 Requests	2 Requests	0.00%	0.00%

Région

Choisir la région la plus proche de chez vos utilisateurs. Pas en termes de distance physique, mais en termes de connexion fibres.

Vérifier que tous vos services sont dans la même région pour la rapidité d'échange de données.

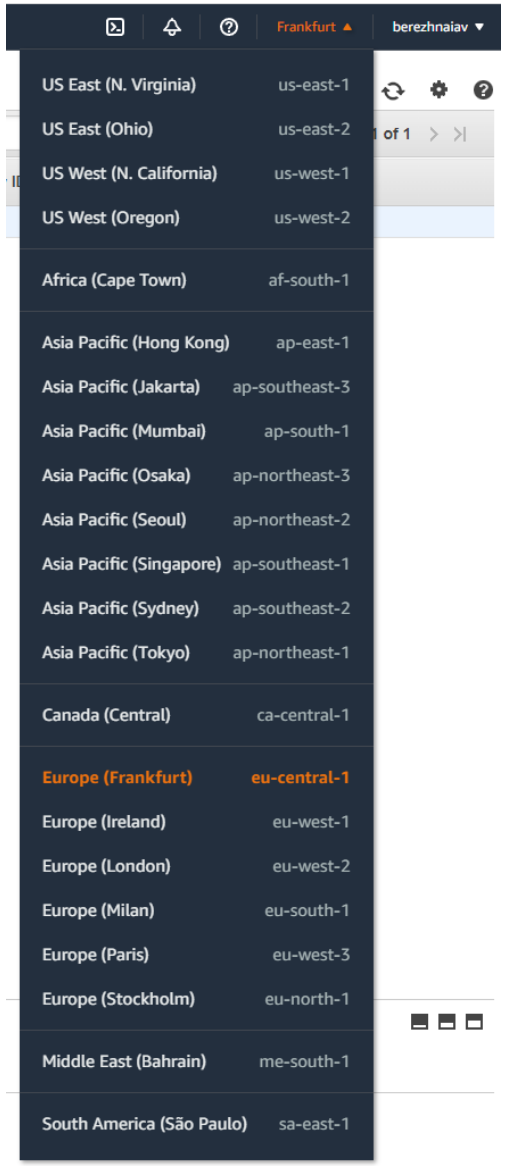

Architecture AWS: l'EC2, l'EBS, l'AMI

EC2 – l'unité de calcul
EBS – ressemble au disque C / disque système sur un ordinateur Windows
VPC – le réseau local
S3 – le stockage de données non structuré
Clusters éphémères: les données sont supprimés après l'exécutions, les résultats sont mis dans la console ou dans un fichier. On l'utilise pour des calculs dont on attend des résultats pas dans l'immédiat (dans l'heure par exemple).

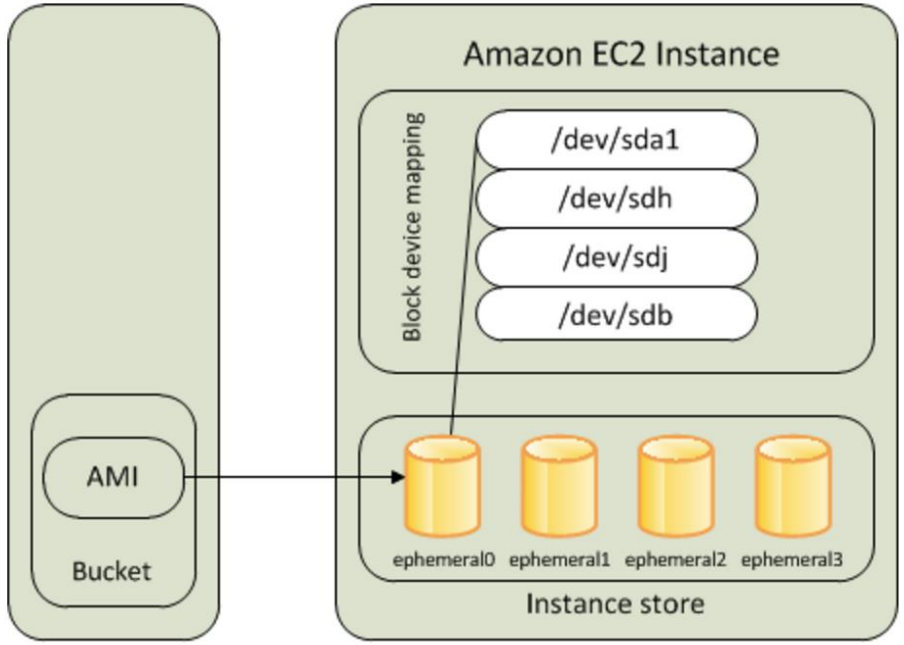

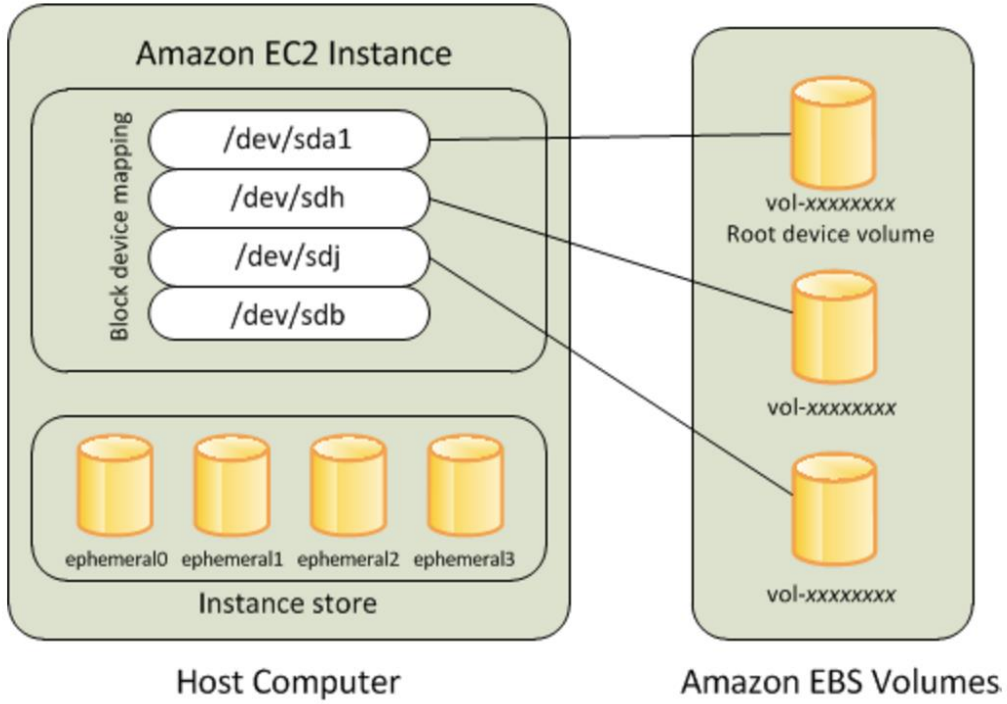

SOURCE DE L'IMAGE ET D'INFORMATION : HTTPS://MICROSOFTGEEK.COM/?P=3079

Sauvegarde de machine (AMI) ou de disque (EBS)

Créer un AMI

L'avantage: plus simple

Le défaut : prend plus de place : chaque fois toute l'instance est sauvegradée, avec le volume entier de tous les disque EBS utilisés

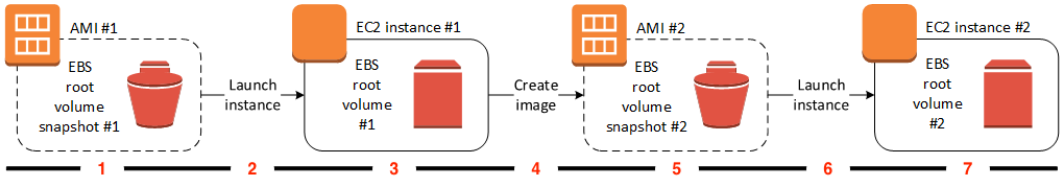

Créer une copie de EBS

L'avantage: économise la place: première sauvegarde la place entière, des suivantes – que des changements.

Le défaut: plus d'étapes à l'appliquer: arrêter le serveur, détacher le disque, rattacher un nouveau, rallumer le serveur.

Dans les deux façons de faire, il ne faut pas oublier de faire le ménage dans vos sauvegardes

SOURCE DE L'IMAGE : HTTPS://DOCS.AWS.AMAZON.COM/AWSEC2/LATEST/USERGUIDE/CREATING-AN-AMI-EBS.HTML

Compartiment S3

Attention à la fuite de données privées sensibles !

« Vous seriez tenus pour responsables en cas de mauvaise configuration, notamment depuis la règlementation européenne sur les données (voir le RGDP, le Règlement général sur la protection des données). »

https://openclassrooms.com/fr/courses/4810836-decouvrez-le-cloud-avec-amazon-web-services/5072136-definir-les-droits-dacces-a-s3

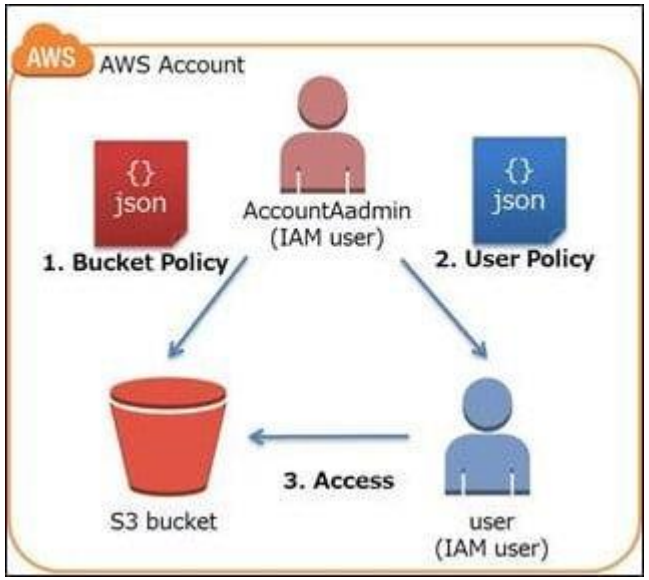

Stockage de fichiers

Gestion d'accès :

Permissions du bucket

Permission d'utilisateur – pour soi, pour des groupes de sécurité, pour la grands publique ayant accès à internet

Versioning – pour réécrire des fichiers

SOURCE D'IMAGE : HTTPS://SUBSCRIPTION.PACKTPUB.COM/BOOK/VIRTUALIZATION-AND-CLOUD/9781785280702/6/CH06LVL1SEC31/WALKTHROUGH-1-TO-GRANT-USERS-BUCKET-PERMISSIONS.

Connecter l'EC2 et le S3 avec un rôle IAM

Elastic IP adresse : pour éviter de changer l'adresse chaque fois quand on rédemarre le serveur

Indiquer l'adresse est nécessaire lorsque l'on accède au serveur par SSH ou encore à S3, car on insère l'adresse serveur dans l'adresse des object dans le bucket.

Établir les connections par SSH:

Entre l'ordinateur et le EC2:

Créer une paire de clés de serveur

Convertir les clés avec PuTTY, s'autoriser en ouvrant une session avec cette paire de clés

Entre le EC2 et le Bucket S3:

Établir un rôle IAM

Créer une paire de clés du Bucket (attention à les sauvegarder) (attention à bien protéger la clé privée)

Insérer les clés au moment de lancer la Spark Session

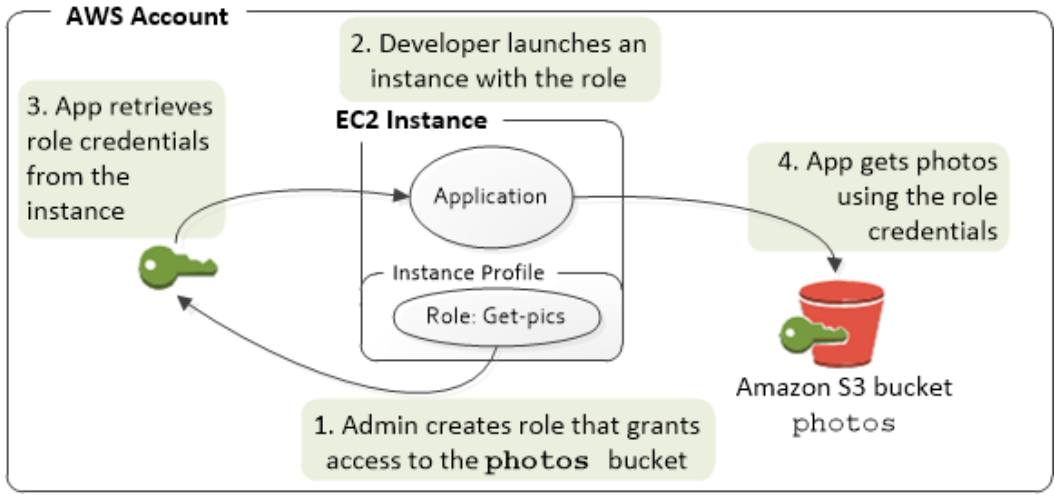

Établir les connections par SSH

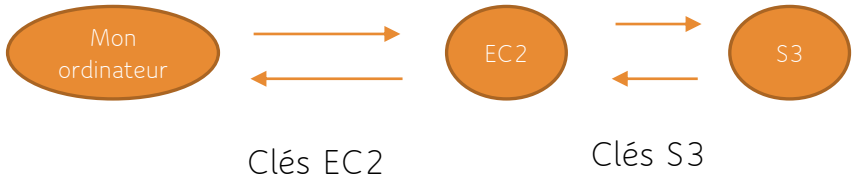

Pensez à sauvegarder la paire de clés
Attention à bien protéger la clé privée !

SOURCE DES IMAGES ET D'INFORMATION : HTTPS://DOCS.AWS.AMAZON.COM/IAM/LATEST/USERGUIDE/ID_ROLES_USE_SWITCH-ROLE-EC2.HTML

L'architecture Big Data

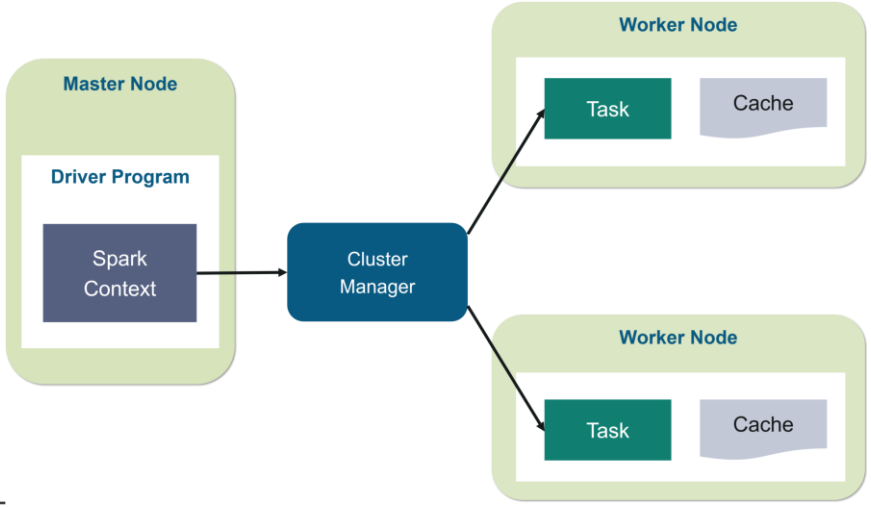

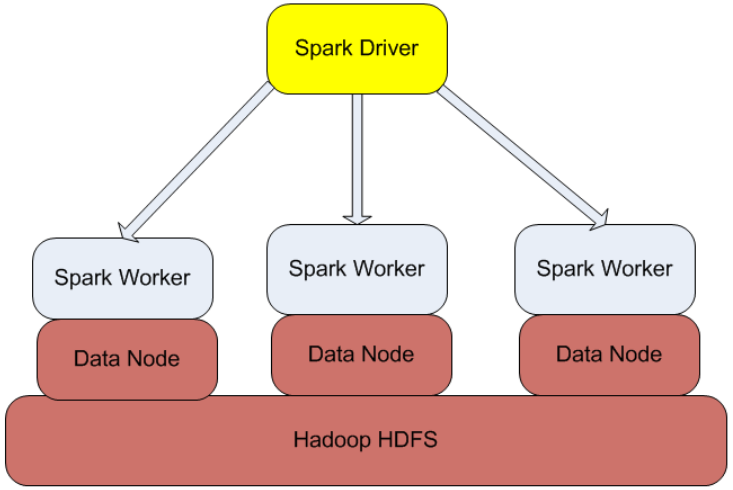

PySpark utilise Hadoop sous son capot.

Hadoop utilise la répartition d'objets à traiter avec la commande «map», puis la recollection avec la commande «reduce», chaque fois suivie par Shuffle.

Nous ne voyons pas ces fonctions map - reduce ; dans le notebook elles ne sont pas utilisées explicitement, ce sont des commandes intérieures de Hadoop.

Par contre la fonction .collect() est équivalente à la commande «reduce» dans Hadoop

Répartitions

Ca fait du sens faire la répartition quand on a plusieurs ordinateurs (EC2), chacun contenant plusieurs processeurs (VPC), mais pas dans notre cas. Nous avons un EC2 de configuration t2.micro, qui a juste un VPC.

SOURCE D'IMAGE ET D'INFORMATION : HTTPS://MICROSOFTGEEK.COM/?P=3079

Code du notebook: préprocessing et la réduction de dimension

Preprocessing

Ouvrir la session

Choisir le modèle (réseau de neurons): taille du modèle, taille de la vecteur de sortie. Le choix de MobileNet

Et comme ce modèle depasse toujours des limites d'offre gratuite, il faut faire le swap: allouer une partie de l'espace EBS à RAM

Input shape : établie si on garde top layer, trop grande pour nos images

Output shape: la couche avant-dernière (conv), pas la dernière (pooling)

Réduction de dimension

Il faut passer de tableau au vecteur

Comme le vecteur est longue, il a fallu agrandir le volume EBS, refuser désormais de sauvegardes, et augmenter le swap.

Pas possible de définir la variance préservée. On n'a qu'à définir le nombre de composants principales.

Contrairement à SKLearn, on peut demander le nombre de composants plus élevé que le nombre d'échantillons. Ca permet de fixer la longueur des colonnes.

Code du notebook: écriture dans le fichier .csv

Il faut rentrer du vecteur au tableau

Il faut convertir le tableau en chaîne de characters

Chaque conversion et chaque opération, comme StandardScaler ou PCA, recrée une nouvelle colonne. J'elimine les colonnes qui ne sont plus nécessaires, mais ça amène à utiliser plus de RAM, car au lieu de une colonne on en a deux après chaque opération.

Conclusions

L'architecture Big Data est déployée, dans la machine locale pour le test et sur le serveur AWS pour la validation et l'évaluation.

Les fichiers correspondantes aux images sont traités grâce aux scriptes PySpark : l'extraction de features d'images avec un réseau de neurones de la bibliothèque Keras, puis la réduction de dimension.

Les donnés sont sauvegardées dans le Bucket S3 sur AWS

L' acces au Jupyter Notebook est rendu publique (avec un mot de passe) aussi que aux objets dans le Bucket : les images d'entrée et la sortie après la réduction de dimension, mais pas les dossiers.

Recommandations

Faire très attention à ne pas dépasser le Free Tier: aussi pour des valeurs statiques (telles que nombre et tailles de EC2, de EBS, de S3) que pour les valeurs dynamiques (quantité de requêtes restante)

Penser à sauvegarder ses paires de clés et faire attention à la sécurité des clés privées

Utiliser le swap de RAM pour rester dans l'offre gratuite

Ne pas oublier de supprimer toutes ses instances après la fin du projet: l'offre gratuit ne dure qu'un an.